Домашка 5: перевірка вірусних ШІ-фейків

Oct 25, 2026 · @Мирослава

Методика

Перевірено 3 матеріали, що вірусно поширювались як справжні у вересні–жовтні 2026: одне відео і два зображення. Кожен пройшов однаковий чекліст; кожен крок записано так, щоб інша людина могла його повторити.

Рівень	Що перевіряємо	Інструменти
0. Фіксація	Зберегти файл, порахувати SHA-256, заархівувати джерельний пост	PowerShell `Get-FileHash`, archive.ph, Wayback Machine
1. Джерело і поширення	Хто опублікував першим, коли, історія акаунта, охоплення	Пошук у соцмережах, архіви
2. Реверс-пошук	Чи існував матеріал раніше, чи є оригінал або автор	Google Lens, TinEye, Yandex; для відео — ключові кадри через InVID-WeVerify
3. Метадані і провенанс	EXIF, C2PA-маніфест, мітки «Made with AI» на платформах	ExifTool, contentcredentials.org/verify, OpenAI Verify
4. Криміналістика і артефакти	Логотипи, текст, руки й обличчя, тіні, фізика; ELA та шум	Forensically, FotoForensics, InVID-WeVerify
5. Перевірка змісту	Чи відповідає подія реальності: офіційні заяви, хто був присутній	Офіційні джерела, фактчекери
6. Автоматичні детектори	Ймовірність генерації ШІ (score)	Hive, Sightengine, Sensity, Deepware (для відео)

Шаблон кожного кейсу: твердження → фіксація (файл, SHA-256, архів) → рівні 1–6 → вердикт. Комірки «→ вписати» заповнюються за результатами власного прогону.

Кейс 1. Відео «40-годинні черги на кордоні з Польщею»

Вердикт: фейк, відео згенероване ШІ. ДПСУ спростувала черги, а логотип UNN підроблений.

Поле	Результат
Твердження	Через російські атаки та заходи безпеки черги до Польщі сягають 40 годин (Дорогуськ) і доби (Гребенне). ШІ-голос за кадром
Тип	Відео з логотипом, схожим на UNN
0. Файл і SHA-256	→ вписати назву файлу та хеш
0. Архів	→ вписати посилання archive.ph на пост «Труха Луцьк»
1. Джерело і поширення	17.10.2026, майже одночасно в Telegram, Instagram, Facebook і TikTok. «Труха Луцьк»: 54,2 тис. переглядів, підпис «… – ЗМІ». На Facebook і TikTok — сторінки, стилізовані під UNN. Підхопили WP Wiadomości, Kresy.pl і «Первый канал» (IMI)
2. Реверс-пошук	→ витягти ключові кадри в InVID-WeVerify і перевірити в Google Lens; фактчекери цього не описують
3. Метадані і провенанс	→ ExifTool та contentcredentials.org/verify. Очікувано: метадані затерті після перестискання соцмережею
4. Артефакти	Логотип чорний, а в справжнього UNN синій (IMI). → дописати свої спостереження: номери авто, написи, рух машин, люди

Поле	Результат
5. Перевірка змісту	Речник ДПСУ Андрій Демченко: значних черг легкових авто не зафіксовано; кордон перетнули ≈ 92 тис. (п'ятниця), 104 тис. (субота), ≈ 100 тис. (неділя) осіб. UNN цього відео не публікував. Спростування ЦСКР: t.me/spravdi/59116
6. Детектори	Hive: 99,7 % ШІ (за даними ЦСКР). Власний прогін — у таблиці детекторів нижче

Кейс 2. Фото «протестувальники роздягли літню пару» у Франції

Вердикт: фейк, зображення згенероване в ChatGPT. Авторка сама це підтвердила BBC Verify.

Поле	Результат
Твердження	Під час заворушень у Франції протестувальники напали на літню пару, роздягли її і пограбували
Тип	Зображення (монтаж із кількох кадрів)
0. Файл і SHA-256	→ вписати назву файлу та хеш
0. Архів	→ вписати посилання archive.ph на пост з зображенням або на статтю France 24
1. Джерело і поширення	Найраніша версія — монтаж на сайті Infos-Israel.news ввечері 17.10.2026 (France 24, Full Fact). Репост без мітки в X набрав понад 6 млн переглядів (BBC)
2. Реверс-пошук	Послідовність версій веде до публікації 17.10 на Infos-Israel.news; справжнього фото-оригіналу не знайдено. → вписати свій результат Google Lens / TinEye

Поле	Результат
3. Метадані і провенанс	Оригінал мав мітки «Made with AI» у X і «AI content» в Instagram; вірусні репости їх втратили. → перевірити файл в contentcredentials.org/verify і OpenAI Verify (ChatGPT додає C2PA-маніфест, але соцмережі часто його зрізають)
4. Артефакти	Фактчекери конкретних артефактів не наводять. → дописати свої спостереження: руки, обличчя на фоні, написи, тіні; ELA у Forensically
5. Перевірка змісту	Директорка Infos-Israel.news Сабріна Анія заявила BBC Verify, що зображення зроблене в ChatGPT без референсу. Прокуратура Парижа станом на 19.10 не отримувала заяв про такий напад (Libération CheckNews)
6. Детектори	Фактчекери score не публікували. Власний прогін — у таблиці детекторів нижче

Кейс 3. «Селфі» світових лідерів на саміті BRICS 2026

Вердикт: фейк, зображення згенероване ШІ. На ньому є люди, яких на саміті не було, зокрема Ебрагім Раїсі, який загинув у травні 2024.

Поле	Результат
Твердження	Справжнє селфі Путіна, Лули да Сілви, Мохаммеда бін Заїда, Моді, Сі Цзіньпіна, Ердогана, Рамапхоси і Раїсі на саміті BRICS (Нью-Делі, 12–13.09.2026)
Тип	Зображення
0. Файл і SHA-256	→ вписати назву файлу та хеш
0. Архів	Готові архіви постів: archive.ph/1DVmJ (Asianet Hindi), archive.ph/K5OZg, archive.ph/x8FYX, archive.ph/wuyPy
1. Джерело і поширення	Поширювалось у соцмережах під час саміту; індійське ЗМІ Asianet Hindi опублікувало його як справжнє (The Quint)

Поле	Результат
2. Реверс-пошук	→ вписати результат Google Lens / TinEye. Для порівняння є справжні фото саміту: пост Моді, пост MEA India
3. Метадані і провенанс	OpenAI Verify показав, що зображення створене інструментами OpenAI (The Quint). → повторити перевірку та додати contentcredentials.org/verify
4. Артефакти	→ дописати свої спостереження: рука, що тримає телефон, обличчя, відбитки, фон
5. Перевірка змісту	Бразилію представляв міністр закордонних справ Мауру Вієйра, а не Лула. ОАЕ представляв наслідний принц Халед бін Мохаммед, а не Мохаммед бін Заїд. Президент Туреччини не був присутній. Раїсі загинув у травні 2024
6. Детектори	Hive: 99,9 % ШІ, Sightengine: 99 %; обидва вказали на ChatGPT як ймовірне джерело (The Quint). Власний прогін — у таблиці детекторів нижче

Порівняння детекторів

Детектори попередньо згодні між собою: усі опубліковані оцінки ⩾ 99 %. Перша колонка — значення фактчекерів, решта заповнюється за власним прогоном того самого файлу (з тим самим SHA-256).

Кейс	Hive, за фактчекерами (% ШІ)	Hive, власний прогін (% ШІ)	Sightengine, власний прогін (% ШІ)	Дата прогону	Розбіжність
1. Черги на кордоні (відео)	99,7	→	→ (стоп-кадр)	→	→
2. Літня пара у Франції (фото)	не публікували	→	→	→	→
3. Селфі BRICS (фото)	99,9 (Sightengine: 99)	→	→	→	→

На що звернути увагу під час прогону:

- Результат залежить від якості файлу: копія, перестиснута Telegram чи скріншот, може дати нижчий score. У схожому відеофейку з кораблем Hive дав лише 81,1 % на відео, а Sightengine — 99 % на стоп-кадрі (Lead Stories).
- Score — це ймовірність, а не доказ: детектор не пояснює, чому він так вирішив.
- Записати дату прогону і зробити скріншот результату: моделі детекторів оновлюються, і через місяць score може бути іншим.

Висновок

Найбільше інформації дали рівні **1 (джерело)** і **5 (перевірка змісту)**. Лише вони довели фейк у всіх трьох випадках, і довели так, що це може перевірити будь-хто.

Кейс	Вирішальний доказ	Рівень
1. Черги на кордоні	ДПСУ навела реальні цифри перетинів без значних черг; UNN відео не публікував	5, 1
2. Літня пара у Франції	Авторка зображення визнала, що згенерувала його в ChatGPT; прокуратура не отримувала заяв	1, 5
3. Селфі BRICS	На фото Раїсі, який помер у 2024, і лідери, яких не було на саміті	5

Чому саме вони:

- **Вони пояснюють, а не лише оцінюють.** Детектор каже «99 % ШІ», але не каже, що саме неправда. Перевірка змісту показує, що черг не було, а людей на фото там бути не могло.
- **Вони відтворювані.** Заяву ДПСУ чи дату смерті Раїсі будь-хто перевірить за посиланням, а score детектора змінюється з версією моделі та якістю файлу.
- **Стійкість до перестискання.** Метадані й C2PA (рівень 3) соцмережі зрізають, тож у вірусних копіях їх зазвичай немає. Мітка «Made with AI» у випадку 2 залишилась лише на оригіналі, який знайшли через рівень 1.

Детектори (рівень 6) корисні для швидкого сортування: вони за секунди показують, що матеріал варто перевіряти глибше. Але самі по собі вони не доказ, а підтверджувальний сигнал.

Антибіас-перевірка

- [ ] Чи шукала я дані, що суперечать висновку (наприклад, справжні фото черг тих дат)?
- [ ] Альтернативна гіпотеза розглянута: справжнє відео з іншого часу або місця, а не генерація?
- [ ] Кожен факт фактчекерів перевірено за первинним джерелом?
- [ ] «Не знайдено» записано як «не знайдено», а не як «не існує» (автора відео з кейсу 1 не встановлено)?
- [ ] Розбіжності детекторів задокументовано, а не «вирішено»?

Джерела

- IMI: ШІ-відео про фейкові черги на кордоні з Польщею, 21.10.2026
- Inform.zp.ua: ДПСУ спростувала ШІ-фейк, 22.10.2026
- ЦСКР у Telegram
- France 24 Observers · BBC · Full Fact — цитовані за оглядом Erkan Saka, 22.10.2026
- The Quint WebQoof: штучне фото лідерів на BRICS 2026, 13.09.2026
- Lead Stories: ШІ-відео корабля, 08.10.2026 (для порівняння детекторів)

Інструменти: Hive · Sightengine · Content Credentials · Forensically · FotoForensics · archive.ph